Lab 12: Turniej Modeli

Ewaluacja, porównanie i finał

Jarosław Hryszko
jaroslaw.hryszko@uj.edu.pl

Instytut Informatyki i Matematyki Komputerowej UJ

Otwarte repozytoria kodu i pomiary oprogramowania

Gdzie jesteśmy?

Podróż przez 12 labów

1. Laby 1–3: Git, GitHub API, Docker — **infrastruktura**
2. Laby 4–7: LOC, CC, OO, churn — **metryki kodu**
3. Laby 8–9: SonarQube, dług techniczny — **platformy**
4. Laby 10–11: dataset, 3 modele — **predykcja defektów**
5. **Lab 12: ewaluacja i podsumowanie — dziś!**

Efekty kształcenia: W1, U2

Problem z accuracy

Przypomnienie z lab11

Dataset: 90 clean, 10 buggy. Model „zawsze clean”: accuracy = 90%, ale recall (buggy) = 0%.

Potrzebujemy **więcej metryk**:

- **Precision** Z oznaczonych buggy, ile naprawdę jest buggy?
- **Recall** Z naprawdę buggy, ile model znalazł?
- **F1** Harmoniczna średnia precision i recall
- **AUC-ROC** Pole pod krzywą ROC — ogólna jakość rankingu

Krzywa ROC

- Oś X: False Positive Rate (FPR)
- Oś Y: True Positive Rate (TPR = Recall)
- Każdy punkt = inny próg decyzyjny
- **AUC = 0.5**: model losowy
- **AUC = 1.0**: idealny model
- Im bardziej w lewy górny róg, tym lepiej

```
      TPR
1.0 |.....***
    |...**
    |..*
    |**
0.0 +----
  0.0 1.0
     FPR
```

(ASCII art — prawdziwy wykres w notebooku)

Cross-validation

Problem

Jeden podział train/test może być przypadkowy. Wyniki zależą od tego, które próbki trafiły do testu.

Rozwiązanie: k-fold cross-validation

1. Podziel dane na k części (foldów)
2. Dla każdego foldu: trenuj na $k-1$ częściach, testuj na 1
3. Powtórz k razy — każdy fold raz jako test
4. Wynik: k pomiarów $\Rightarrow$ średnia $\pm$ odchylenie standardowe

Stratified k-fold: zachowuje proporcje klas w każdym foldzie.
Używamy $k = 10$ (standard w literaturze).

Plan zajęć

1. **Zadanie 1 — Metryki ewaluacji** (30 min)
   - Precision, recall, F1, AUC-ROC dla 3 modeli
   - Krzywe ROC na jednym wykresie
2. **Zadanie 2 — Cross-validation** (60 min)
   - 10-fold stratified CV
   - Tabela porównawcza: model $\times$ metryka (mean $\pm$ std)
   - Boxploty wyników
3. **Zadanie 3 — Raport końcowy** (45 min)
   - Podsumowanie: projekt, dataset, modele, wnioski
   - Ograniczenia i co zrobilibyśmy inaczej

Co oddajecie?

W branchu `lab12_nazwisko1_nazwisko2`:

1. `model_tournament.ipynb` — wypełniony notebook z ewaluacją
2. Raport końcowy (w notebooku lub osobnym `report.md`)

Ostatni raz: do roboty!

Instrukcja: `README.md` w repozytorium

"Hunger Games, ale dla algorytmów. Niech zwycięży najlepszy model!" — anonimowy data scientist

Dziękuję za cały semestr!